

Plataforma Distribuida en la Nube para la Detección de Estados Emocionales mediante Análisis Computacional de Escritura Manuscrita usando Deep Learning

Santiago Carmona Pineda
Maria Paula Rodriguez Muñoz

Resumen

Los trastornos de salud mental, tales como la ansiedad, el estrés y la depresión, representan un desafío crítico para instituciones educativas, servicios psicológicos y programas de bienestar organizacional. Si bien la detección temprana es fundamental para reducir su impacto social y económico, los enfoques digitales actuales dependen principalmente de datos autorreportados, análisis de texto o señales biométricas invasivas, lo que limita su aplicación en contextos institucionales de gran escala.

La escritura manuscrita, entendida como una actividad psicomotora compleja influenciada por estados emocionales y neuropsicológicos, surge como una fuente de datos no invasiva con alto potencial para el análisis conductual. Aunque históricamente la grafología careció de validación científica y reproducibilidad, los avances recientes en visión por computador y Deep Learning permiten replantear este análisis mediante un enfoque cuantitativo y automatizado basado en datos.

En este trabajo se propone una plataforma distribuida en la nube orientada al análisis masivo de escritura manuscrita digitalizada, utilizando arquitecturas híbridas de Deep Learning (CNN y Vision Transformers) para identificar patrones asociados a estados emocionales. La solución adopta un modelo multitenante (multitenant) que permite el procesamiento simultáneo de datos para múltiples organizaciones. Las contribuciones principales consisten en la

integración de inteligencia artificial aplicada a la salud mental bajo un enfoque tecnológico estructurado, escalable y éticamente responsable, orientado al análisis emocional no diagnóstico en entornos institucionales reales.

1. Introducción

En la actualidad es imposible ignorar el hecho de que la salud mental se ha vuelto uno de los temas más urgentes a nivel mundial, ya que los datos de la OMS son contundentes: se estima que más de 970 millones de personas viven con algún trastorno mental, una problemática que la pandemia de COVID-19 agravó al incrementar los índices de ansiedad y depresión, especialmente en entornos educativos y laborales. Teniendo en cuenta esto, la detección temprana de estas señales requiere atención inmediata, no se trata solo de un tema clínico, sino de una necesidad real para las organizaciones que manejan muchos usuarios y necesitan herramientas objetivas, que no sean invasivas y escalables para identificar estas señales de riesgo a tiempo. Una de las formas más interesantes de abordar esto es a través de la escritura manuscrita. Escribir no es solo mover la mano; es una actividad psicomotora compleja donde se mezclan procesos cognitivos y neuromotores con nuestras emociones. Por ello detalles como: qué tanto presionamos el papel, la inclinación de las letras o incluso el tamaño de los trazos dicen mucho sobre cómo nos sentimos.

Históricamente la grafología intentó estudiar esto siempre con la limitación de ser muy subjetiva y de no poder contar con modelos estadísticos sólidos que permitieran replicar sus resultados de manera científica, de ahí nace la motivación de este trabajo. Con los avances que hay hoy en día de visión por computador y Deep Learning, existe la oportunidad de analizar la escritura manuscrita de una manera cuantitativa y automática. Sin embargo nos hemos dado cuenta de que la investigación actual suele limitarse al modelo de inteligencia artificial y omite la implementación real. Realmente no sirve mucho tener un modelo preciso si no puede funcionar en una plataforma que soporte miles de usuarios de distintas organizaciones al mismo tiempo, convirtiéndose este en el problema central que queremos resolver.

Como respuesta a este problema, se propone el diseño de una plataforma distribuida en la nube para la detección de estados emocionales mediante análisis computacional de escritura manuscrita usando Deep Learning integrando tres áreas clave: la inteligencia artificial, la psicología computacional y los sistemas distribuidos.

Más específicamente el trabajo aporta tres elementos principales: un modelo híbrido, es decir combinar CNN con ViT para capturar tanto los pequeños detalles del trazo como la estructura general de la escritura; una arquitectura cloud-native basada en

microservicios que permite procesar de manera asíncrona y que sea multitenencia; por último un gobierno de datos, es decir implementar un marco que asegure que la información sea anónima dejando claro que la plataforma no es una herramienta de diagnóstico médico sino un sistema de apoyo.

2. Motivación y Estado del arte

La motivación de este proyecto nace de una necesidad muy clara identificada en la literatura técnica disponible. A pesar de que existe mucha evidencia científica que vincula nuestra manera de escribir con nuestro estado emocional, aún falta dar ese paso a la práctica. No existe hoy una plataforma tecnológica bien estructurada que permita aprovechar esta relación de forma automática, que sea fácil de replicar y sobre todo que pueda funcionar a gran escala dentro de una organización. En los siguientes puntos se resume cómo está el panorama actual en áreas que tocan este tema, destacando lo que se ha avanzado y los vacíos que aún faltan por llenar.

2.1. Modelos de Aprendizaje Profundo y Atención

Las investigaciones más recientes en IA han dejado de depender solo de redes convolucionales (CNN) tradicionales para empezar a usar mecanismos de atención. En este caso, el estudio de PeerJ Computer Science (2024) habla de que aplicar Transformers a muestras de escritura o dibujo permite captar dependencias espaciales que las CNN normalmente pasan por alto, lo cual es clave porque para identificar emociones complejas, no basta con mirar un trazo de forma aislada, hay que entender cómo se relacionan todos los elementos de la escritura en conjunto. Sin embargo, una limitación crítica de estos modelos es su alto costo computacional, lo que dificulta su ejecución en tiempo real dentro de plataformas con múltiples usuarios concurrentes. Por otro lado, un problema muy común en el área de la salud mental digital es que no hay suficientes bases de datos etiquetadas con emociones reales. Para solucionar esto, autores como Qi et al. (2024) proponen el uso de Redes Generativas Antagónicas (GAN) para generar más datos (Data Augmentation), lo que ayuda a que los modelos sean mucho más robustos a pesar de la falta inicial de muestras. El punto crítico aquí es que, aunque estos trabajos mejoran la precisión del modelo, se centran solo en el algoritmo y no explican cómo manejar el flujo de datos en tiempo real dentro de una arquitectura escalable, que es precisamente lo que este proyecto propone resolver.

2.2. Psicología Computacional

En el ámbito de la psicología, trabajos recientes como el de Soni y Kumari (2026) plantean que la escritura manuscrita es mucho más que una firma; funciona como un “biomarcador dinámico”. Lo interesante de estos avances en este último año es que el análisis de la presión y la variabilidad del trazo, ya sea mediante tablets o analizando imágenes estáticas con visión por computador, alcanza una correlación de más del 85 % con escalas de ansiedad que usan los profesionales en sus consultas, demostrando que el potencial clínico es muy grande. A pesar de este gran potencial clínico, estos avances suelen quedarse en el análisis estadístico o en el consultorio. Falta una infraestructura técnica que saque este conocimiento del laboratorio y lo ponga al servicio de instituciones de forma masiva y automática.

2.3. Sistemas Distribuidos y Multimodalidad

Aunque hasta ahora el reconocimiento de emociones se ha centrado mucho en el análisis facial (como se ve en los surveys de 2021 y 2022 sobre Group-level Emotion Recognition), cada vez se buscan sistemas que sean menos invasivos. Al revisar la literatura de 2023 y 2024, se identifica que el gran vacío no está en la precisión de los modelos sino en su implementación.

La mayoría de los estudios se quedan en pruebas controladas de laboratorio y no se integran en arquitecturas que sean cloud-native. Nuestra propuesta busca cambiar eso, utilizando principios de procesamiento distribuido para que el análisis no se quede en un experimento, sino que sea una herramienta escalable que varias organizaciones puedan usar al mismo tiempo sin colapsar el sistema.

En conclusión, el vacío de conocimiento (gap) identificado es la desconexión entre la precisión de los modelos de IA y la capacidad de las arquitecturas actuales para soportar procesos de inferencia emocional de forma masiva y multitenante. Este trabajo aborda dicho problema diseñando una solución que une la potencia del Deep Learning con una infraestructura distribuida y escalable.

3. Marco teórico

En esta sección se presentan los conceptos fundamentales que sirven de base para el desarrollo de la plataforma. En lugar de centrarnos en una sola área, el proyecto se apoya en cuatro pilares clave. Por un lado está la parte humana, que estudia los movimientos finos y su carga emocional, y por otro la técnica, donde aplicamos Deep Learning al análisis de imágenes. Todo esto integrado mediante la psicología

computacional y una base sólida de ingeniería de sistemas.

3.1. Críticas a la grafología tradicional

La grafología surge en el siglo XIX con autores como Michon y Crépieux-Jamin, quienes planteaban que era posible conocer la personalidad de alguien solo analizando su escritura. Aunque se usó mucho durante el siglo XX en procesos de selección y forenses, más tarde la ciencia terminó dejándola de lado. El problema principal es que carece de validez predictiva, es demasiado subjetiva y no tiene un respaldo estadístico sólido. Por eso, hoy en día no se considera una herramienta válida en la psicología científica, y es importante separar lo que hacemos en este trabajo de ese tipo de prácticas antiguas. Nuestra propuesta se desplaza hacia la grafometría computacional, utilizando modelos reproducibles que eliminan el sesgo del evaluador humano.

3.2. Relación entre motores finos y emociones

Escribir a mano es un proceso complejo que empieza con una intención en el córtex prefrontal y termina en un movimiento preciso de la mano. Lo interesante es que este proceso se ve alterado por el estado interno de la persona. Por ejemplo, cuando alguien tiene ansiedad, el sistema nervioso autónomo genera tensión muscular y hace que el ritmo o la presión del trazo cambien. Con la depresión pasa algo similar: suele haber lentitud motora, letras más pequeñas y menos orden en el espacio. Si se analiza de forma cuantitativa, la escritura se vuelve un canal objetivo para identificar estos estados sin depender solo de lo que el paciente dice, conectando la respuesta neuromuscular con los modelos de IA que se describen a continuación.

3.3. Análisis de escritura con Deep Learning

Para analizar estas imágenes, las Redes Neuronales Convolucionales (CNN) son la herramienta estándar, ya que detectan muy bien detalles como la curvatura de los trazos o la presión (inferida por la intensidad de los píxeles). El problema con las CNN es que, por su propia estructura, a veces les cuesta conectar los puntos entre elementos que están muy alejados dentro de una misma imagen. Aquí es donde entran los Vision Transformers (ViT), que procesan la imagen en fragmentos y usan mecanismos de autoatención para entender dependencias globales. Teniendo esto en cuenta, este proyecto no se queda con una sola herramienta, sino que combina ambas en una arquitectura híbrida: aprovechamos la capacidad de las CNN para los detalles locales y el potencial de los ViT para el contexto general de la escritura.

3.4. El enfoque de la psicología computacional

Esta disciplina mezcla modelos matemáticos con IA para entender y predecir procesos psicológicos. Ya se ha visto que funciona bien detectando depresión mediante el lenguaje (NLP) o señales fisiológicas, pero lo que diferencia a este proyecto es que usamos la escritura a mano como señal principal. Combinamos los biomarcadores conductuales ya conocidos con visión por computador. Es importante dejar claro que el sistema se limita al screening preventivo; es decir, busca identificar posibles señales de alerta o patrones de riesgo, pero en ningún momento pretende sustituir un diagnóstico clínico oficial. Mantener esta distinción es clave, sobre todo por una cuestión de ética profesional.

3.5. Plataformas digitales y analítica de datos

Hoy en día, cualquier solución en el ámbito de la salud necesita una plataforma capaz de gestionar grandes volúmenes de datos para que la toma de decisiones sea útil. No se trata solo de recolectar información, sino de que el sistema sea capaz de generar alertas automáticas a tiempo. Llevar los modelos de IA a una interfaz digital permite que todo el proceso se automatice; así, el análisis deja de ser esa tarea manual que suele quitar tanto tiempo y se convierte en algo mucho más dinámico, donde los resultados aparecen prácticamente al momento.

3.6. Procesamiento de datos y escalabilidad

Si el plan es que mucha gente use la plataforma a la vez, la eficiencia es fundamental. Ahí es donde entra la escalabilidad, ya que necesitamos que el sistema soporte una carga de trabajo alta sin que se cuelgue o se vuelva lento. Para un entorno institucional, donde se exige que todo funcione rápido y esté siempre disponible, la arquitectura tiene que estar muy bien armada para gestionar muchísimas solicitudes y bases de datos pesadas sin perder estabilidad.

4. Descripción y caracterización del problema

El problema central de este proyecto es la falta de plataformas digitales que sean realmente escalables y estén bien estructuradas para analizar la escritura manuscrita de forma objetiva. Aunque existen avances en inteligencia artificial aplicada a la salud mental, la mayoría de los desarrollos se quedan en soluciones aisladas, sin pensar en cómo integrar estos modelos en sistemas capaces de atender a miles de usuarios o de funcionar para distintas organizaciones al mismo tiempo. Esta brecha se puede

analizar desde tres ángulos principales, presentados a continuación.

4.1. Limitaciones del análisis tradicional de la escritura

El gran problema de la grafología clásica es que siempre ha sido demasiado subjetiva, ya que depende demasiado del criterio del evaluador, lo que genera resultados poco confiables. Debido a la ausencia de modelos estadísticos sólidos, la comunidad científica ha terminado por descartarla como una herramienta válida para la psicología (Driver et al., 1996). Si bien existen patrones como la presión del trazo o la inclinación de las letras que sí tienen un vínculo probado con las emociones (Lorusso et al., 2018), la solución no está en dejar de lado el análisis de la escritura, sino en automatizarlo a través de un enfoque cuantitativo que se pueda replicar sin sesgos.

4.2. Limitaciones de los enfoques actuales de IA en salud mental

Hoy en día, casi todo lo que se hace en IA para salud mental se basa en analizar textos (NLP), publicaciones en redes sociales o el uso de señales biométricas que suelen ser bastante invasivas. Aunque funcionan, tienen limitaciones: los datos pueden estar sesgados, incompletos o depender totalmente de que el usuario quiera contar cómo se siente. Además, suelen ser modelos independientes que no se integran en arquitecturas más grandes o reutilizables. En este escenario, la escritura manuscrita es una fuente de información muy rica, accesible y poco invasiva que sigue estando muy desaprovechada en el campo tecnológico.

4.3. Brecha tecnológica y organizacional

Desde el punto de vista de la ingeniería, hay una desconexión enorme entre los modelos experimentales de inteligencia artificial y su implementación en entornos reales. Muchos trabajos se enfocan en mejorar métricas de precisión, pero se olvidan de aspectos que son fundamentales para su implementación en un entorno real, como la escalabilidad para grandes volúmenes de usuarios concurrentes, una latencia aceptable en el procesamiento, la alta disponibilidad del sistema y la capacidad de operar bajo múltiples organizaciones simultáneamente (multitenencia). Al final, para que estos modelos tengan un impacto real, la robustez del sistema es tan importante como la precisión al momento de realizar las predicciones.

5. Objetivos

5.1. Objetivo general

El objetivo es diseñar e implementar una plataforma distribuida que sea multitenant. Para esto usaremos arquitecturas de Deep Learning (específicamente Vision Transformers y CNN), con el fin de analizar la escritura a mano de forma masiva para detectar patrones emocionales a escala en diferentes entornos institucionales.

5.2. Objetivos específicos

- Revisión del estado del arte y fundamentos: Investigar qué se está haciendo hoy en la psicología computacional y modelos de atención (Transformers). Buscamos identificar biomarcadores cinéticos en la escritura digitalizada para poder extraer información que sea realmente relevante sobre el estado de la persona.
- Desarrollo del modelo de IA: Entrenar un modelo híbrido de aprendizaje profundo. Este debe aprovechar los mecanismos de atención para extraer rasgos que no sean textuales. La idea es vincular la dinámica del trazo con estados de ansiedad, estrés o depresión, sin fijarse en el contenido de lo que la persona escribe.
- Diseño de arquitectura Cloud-Native: Diseñar una arquitectura basada en microservicios que sea cloud-native. Queremos garantizar la multitenencia para que clínicas, colegios o empresas puedan usar la plataforma con la seguridad de que sus datos y configuraciones están totalmente aislados.
- Optimización del procesamiento de datos: Implementar un pipeline de procesamiento asíncrono. Esto servirá para manejar cargas masivas de datos, lo cual ayudará a reducir la latencia en las respuestas y asegurar que el sistema escale según la demanda.
- Validación y métricas de desempeño: Validar la precisión del sistema con métricas técnicas. Usaremos (*Accuracy*, *F1-Score*) para comparar los resultados con instrumentos psicométricos ya estandarizados para asegurar la confiabilidad del análisis.
- Gobierno de datos y ética: Definir protocolos claros para el manejo de la información, priorizando la anonimización y la seguridad. Es vital seguir los estándares de salud digital para que la plataforma mantenga su carácter preventivo y no se confunda con un diagnóstico clínico, cumpliendo los requisitos

éticos.

6. Propuesta de solución

Esta propuesta busca resolver, de manera directa, los tres ejes del problema que planteamos antes. Lo que diseñamos es una plataforma distribuida en la nube que une un modelo híbrido de Deep Learning con microservicios multiteniente. El objetivo es que pueda operar en instituciones reales sin complicaciones. En los siguientes puntos explico la arquitectura, los componentes, cómo fluye la escritura por el sistema y cómo manejamos el crecimiento de la carga.

6.1. Arquitectura General del Sistema

Se ha seleccionado una arquitectura cloud-native basada en microservicios para lograr que el sistema sea escalable y soporte fallos de forma estable. Para el manejo de las tareas, el diseño utiliza un enfoque mixto. Por un lado, se emplea comunicación REST para acciones como el ingreso de usuarios o la consulta de resultados. Por otro, se utiliza un modelo orientado a eventos con colas de mensajes para el procesamiento pesado de la IA. Este diseño evita que el procesamiento del modelo afecte la velocidad de la interfaz de usuario. Además, permite que cada componente escale por separado según la demanda de cada momento.

La arquitectura se organiza en cuatro capas lógicas: (1) la capa de cliente, que expone la interfaz web/API; (2) la capa de API y autenticación, que gestiona la entrada segura al sistema; (3) la capa de procesamiento, donde ocurre la carga de imágenes y la inferencia.; y (4) la capa de datos, integra el almacenamiento de archivos y las bases de datos.

6.2. Componentes Principales

La arquitectura se apoya en varios microservicios especializados que trabajan de forma coordinada:

El API Gateway que funciona como el punto de entrada único. Se encarga de guiar las solicitudes, revisar los tokens de seguridad y controlar que el tráfico no sature el servidor. Centralizar estas tareas ayuda a que las reglas de seguridad se apliquen siempre de la misma forma.

El Auth Service gestiona la identidad de usuarios y organizaciones, incluyendo el registro, la generación y validación de tokens, y la asociación de usuarios a sus respectivas organizaciones. Trabaja en estrecha coordinación con el Tenant Mana-

gement Service, que es el responsable de implementar el modelo de multitenencia: crea y configura los tenants, mantiene el aislamiento lógico de sus datos mediante el atributo tenant-id y aplica políticas de Row-Level Security en la base de datos compartida.

El Upload Service recibe las imágenes de escritura, valida sus formatos y las almacena en el sistema de objetos (S3). Una vez completada la carga, publica un evento en el Message Broker, disparando el pipeline de procesamiento. El Preprocessing Service consume este evento y ejecuta las operaciones de normalización de imagen, eliminación de ruido y segmentación de trazos necesarias antes de la inferencia. El AI Inference Service es el núcleo del sistema: ejecuta el modelo híbrido CNN + Vision Transformer, genera las predicciones emocionales con sus métricas de confianza y almacena los resultados a través del Results Service.

6.3. Pipeline de Procesamiento de Escritura

El análisis de la escritura se realiza en tres fases. Primero, las CNN se encargan de observar los detalles locales, como la presión del trazo o la inclinación de las letras. Esto permite obtener una idea de la “textura” emocional de la muestra.

Después, los Vision Transformers analizan la imagen de forma global. Estos modelos observan cómo se relacionan los trazos que están lejos entre sí y el ritmo de toda la línea de escritura. Esto es lo que permite entender el contexto que a las CNN se les suele escapar. Al final, se mezclan ambos resultados para dar una predicción (Ansiedad, Estrés, Depresión o Neutro) con su nivel de confianza. Como se aclaró antes, esto no es un diagnóstico médico, sino una puntuación de riesgo para guiar a un profesional.

6.4. Modelo de multitenencia

Para separar la información entre organizaciones, se utiliza una base de datos compartida pero aislada por código. Cada registro en PostgreSQL lleva su identificador de cliente. Gracias a esto, el sistema filtra los datos automáticamente y una empresa jamás podrá entrar a lo que pertenece a otra. En el almacenamiento de imágenes en S3 se sigue el mismo esquema, usando carpetas separadas por el ID del cliente. Se eligió este camino porque es mucho más económico y fácil de mantener que crear una base de datos física para cada usuario.

6.5. Consideraciones de escalabilidad y despliegue

La arquitectura se monta sobre Kubernetes para que cada microservicio pueda crecer de forma independiente. Si aumenta la demanda de análisis, el servicio de inferencia puede abrir más copias con acceso a GPU, mientras el resto del sistema sigue operando con normalidad. Todo se despliega en contenedores Docker, lo que garantiza que el sistema funcione siempre igual. El tráfico se reparte de forma equitativa para evitar que cualquier parte de la plataforma se sature.

7. Arquitectura del Prototipo

Antes de lanzarse a montar toda la infraestructura distribuida, se diseñó un prototipo para validar si el modelo de inferencia y el flujo de procesamiento realmente funcionan. Esta versión simplificada es clave para iterar rápido sobre el modelo de Deep Learning y medir los tiempos de respuesta sin complejizar la ejecución, de entrada, con la complejidad de un sistema multiteniente.

La Figura 1 muestra el diagrama de arquitectura cloud-native del sistema. El flujo de datos parte del cliente, atraviesa el API Gateway hacia los servicios especializados, y termina en el almacenamiento de resultados tras el procesamiento asíncrono por el AI Inference Service. El Message Broker (Kafka/RabbitMQ) actúa como elemento desacoplador central del pipeline.

7.1. Alcance y simplificaciones

En esta etapa, el prototipo opera bajo una configuración de instancia única y para un solo usuario a la vez (monotenant). Incluye lo básico: una API para subir imágenes, un preprocesamiento sencillo y el modelo de IA corriendo directamente en el backend. Para guardar los datos, se utiliza una base de datos relacional local.

Se decidió dejar fuera, por ahora, las colas de mensajería, el autoescalado y la gestión compleja de organizaciones. Estas piezas son fundamentales para la versión final, pero no hacen falta para probar si el modelo de IA es capaz de dar predicciones de calidad o si el código aguanta variaciones en las fotos. La idea es validar primero la lógica central; una vez que se compruebe que el modelo es robusto, se abordará la arquitectura distribuida. Básicamente, el prototipo es nuestro banco de pruebas.

7.2. Flujo del prototipo

Cuando el usuario sube una imagen por la API, el backend la recibe y arranca el preprocesamiento de forma sincrónica. En este paso se limpia el ruido y se prepara

el archivo para el modelo. Luego, la imagen pasa al servicio de inferencia local, que genera la predicción emocional con su nivel de confianza. Al terminar, el resultado se guarda en la base de datos y se envía de vuelta al usuario como una respuesta HTTP. Aunque este flujo es más simple que el proceso asíncrono que se planea para producción, sirve para medir la latencia del modelo en un entorno controlado, algo vital para calcular qué tanta infraestructura se necesitará después.

7.3. Diagrama de Arquitectura




Figura 1: Diagrama de Arquitectura

El diseño final busca resolver un reto más grande: procesar imágenes de texto a mano con IA, pero de forma masiva y sin que el sistema se bloquee cuando muchos usuarios entren al mismo tiempo.

Todo el flujo arranca en la aplicación web. Para evitar que el cliente se conecte a mil sitios distintos, todas las solicitudes pasan por un API Gateway. Centralizar el acceso así permite gestionar la seguridad y el tráfico de forma mucho más ordenada. Si el usuario necesita entrar a su cuenta, el flujo se desvía al servicio de autenticación, que revisa las credenciales en una base de datos relacional. Aquí también se gestiona la

lógica de los “tenants”, asegurando que los datos de una organización no se mezclen con los de otra.

Una vez que se tiene el acceso, el usuario sube su imagen a través del Upload Service. Este servicio no guarda el archivo en la base de datos común, sino que lo manda a un almacenamiento de objetos (como S3). Es una decisión estratégica para no saturar el sistema con archivos pesados. Pero antes de que la IA entre en escena, la imagen debe pasar por un servicio de preprocesamiento para mejorar su calidad.

Aquí es donde la arquitectura transiciona hacia un modelo. En vez de mandar la imagen directo al servicio de IA, se usa una cola de mensajes. Esto convierte el proceso en algo asíncrono: el preprocesamiento deja un “aviso” en la cola y el servicio de IA lo toma cuando tiene capacidad. Así se evita que el sistema presente una latencia de procesamiento y permite añadir más servidores de IA si el volumen de trabajo sube.

El AI Inference Service es el núcleo funcional de la solución. Toma la imagen limpia y extrae los rasgos con el modelo de Deep Learning. Los resultados obtenidos se guardan en una base de datos NoSQL, ya que estos datos pueden variar mucho en tamaño y necesitamos que la lectura sea muy rápida. Finalmente, cuando el usuario quiere ver sus resultados, el Results Service consulta esa base de datos y le entrega la información organizada a través del mismo Gateway. Al final, cada pieza del sistema tiene un porqué, buscando siempre que la plataforma sea estable y fácil de escalar.

8. Evaluación y Validación

Para validar el sistema, vamos a enfocarnos en dos puntos clave que se complementan. Por un lado, evaluaremos qué tan bien rinde la plataforma a nivel de arquitectura y, por otro, qué tan preciso es el modelo de deep learning. Este proceso se hará por fases: primero probaremos el modelo en el prototipo y después pasaremos a las pruebas de carga en el entorno de producción.

8.1. Evaluación de desempeño arquitectónico

La robustez de la plataforma se medirá con tres indicadores principales. Primero está la latencia de inferencia. La meta es que el tiempo desde que el usuario sube la foto hasta que recibe el resultado no supere los 2 segundos.

También evaluaremos la escalabilidad horizontal. Para esto, mediremos cuántas muestras puede procesar el sistema por minuto a medida que añadimos más réplicas del servicio de IA. Esperamos que el rendimiento crezca de forma lineal. Finalmen-

te, probaremos el aislamiento de recursos entre diferentes organizaciones (tenants). Queremos asegurar que, si una organización satura el sistema, no afecte la velocidad de respuesta de las demás.

8.2. Evaluación del modelo de Deep Learning

Para medir la precisión de nuestra arquitectura híbrida (CNN + Vision Transformer), usaremos métricas de clasificación multiclase. Con la matriz de confusión sacaremos el Accuracy general, pero nos fijaremos especialmente en el F1-Score. Esta métrica es la más importante aquí, ya que categorías como Ansiedad, Estrés o Depresión suelen estar desbalanceadas en los datos. Para asegurar que el modelo funcione con cualquier estilo de letra y no solo con los ejemplos de entrenamiento, aplicaremos una validación cruzada de tipo K-Fold ($K = 5$). También es fundamental que el sistema sea resistente a problemas comunes de digitalización, como la mala iluminación, las manchas o si la hoja está algo torcida. Probaremos esto usando datos degradados artificialmente, ya que en el mundo real no siempre se tienen condiciones de captura perfectas.

8.3. Evaluación Clínica y Ética

Para comprobar si las predicciones tienen sentido clínico, compararemos los resultados con tests psicométricos ya validados. Usaremos el PHQ-9 para detectar síntomas de depresión y el STAI para la ansiedad. No buscamos que el sistema dé un diagnóstico médico, sino establecer que sus predicciones se alinean con estas evaluaciones de referencia a nivel de screening.

En cuanto a la ética, el sistema está pensado solo como una herramienta preventiva. Queremos minimizar los falsos positivos para no generar alarmas que no corresponden. Además, todos los datos se anonimizarán antes de guardarse para proteger la privacidad. El despliegue de la plataforma dependerá totalmente de que se cumplan las normas de salud digital y de que los usuarios den su consentimiento informado.

9. Conclusiones

Este trabajo presenta una propuesta técnicamente fundamentada para abordar la brecha entre los modelos de inteligencia artificial orientados a salud mental y su implementación real en entornos institucionales. La plataforma propuesta integra tres contribuciones principales: un modelo híbrido CNN + Vision Transformer para el análisis de escritura manuscrita, una arquitectura cloud-native multiteniente que

garantiza escalabilidad y aislamiento entre organizaciones, y un marco de gobierno de datos éticamente responsable. Desde el punto de vista técnico, la combinación de CNN y Vision Transformers representa una solución sólida para el problema de extracción de características en escritura manuscrita, ya que capitaliza la extracción local de rasgos de las primeras con la contextualización global de los segundos. La evidencia en la literatura particularmente la correlación superior al 85 % reportada por Soni y Kumari (2026) entre patrones de escritura y escalas de ansiedad validadas apoya la viabilidad de este enfoque.

Desde el punto de vista arquitectónico, el diseño basado en microservicios con procesamiento asíncrono orientado a eventos resuelve la desconexión entre precisión de modelo y escalabilidad operacional que caracteriza a los trabajos previos. La multitenencia con aislamiento lógico por tenant-id permite que la plataforma sea económicamente viable al compartir infraestructura entre organizaciones sin comprometer la privacidad de sus datos.

El trabajo tiene limitaciones importantes que deben reconocerse. La escasez de datasets etiquetados con validación psicométrica rigurosa es el principal obstáculo para el entrenamiento del modelo, y las técnicas de data augmentation mediante GAN son un paliativo pero no una solución definitiva. Adicionalmente, el sistema está limitado a escritura sobre papel digitalizado, lo que excluye la escritura sobre tablets o stylus modalidades que ofrecerían datos cinéticos adicionales como velocidad y presión real del lápiz.

Referencias

- [1] Soni, A. K., & Kumari, D. (2026). Exploring Emotion Recognition through Handwriting Analysis: A Comprehensive Review. *International Journal of Scientific Research & Engineering Trends*, 12(1). ISSN (Online): 2395-566X.
- [2] PeerJ Computer Science. (2024). *Emotion detection from handwriting and drawing samples using an attention-based transformer model*. PeerJ Publishing.
- [3] Qi, H., Zeng, G., Jia, K., Zhang, C., Wu, X., Li, M., Lang, Q., & Wang, L. (2024). Emotion Recognition Based on Handwriting Using Generative Adversarial Networks and Deep Learning. *Deep Learning & Intelligent Systems*. First published: 27 May 2024.
- [4] Kumar, S., et al. (2023). Real time handwriting recognition system using CNN algorithms. *International Conference on Computational Intelligence*.

- [5] Sahu, A., & Singh, R. (2022). Deep Learning based Framework for Emotion Recognition using Facial Expression. *Journal of Image and Graphics*.
- [6] Zheng, X., et al. (2021). A Survey of Deep Learning for Group-level Emotion Recognition. *JOURNAL OF LATEX CLASS FILES*, 14(8).
- [7] Lorusso, R., Plebani, M., & Bresciani, R. (2018). Is Graphology Useful in Assessing Major Depression? *Psychological Reports*, 121(6), 1018–1030.
- [8] Driver, R. W., Buckley, M. R., & Frink, D. D. (1996). Should we write off graphology? *International Journal of Selection and Assessment*, 4(2), 78–86.